Da necessidade ao problema preditivo

Aula 2 — 10/09/2026

Prof. Dr. Aléssio Tony Cavalcanti de Almeida
Ciência de Dados para Negócios – UFPB

João Pessoa, 2026

MLS ▪ 2026.2

Abertura

1

Introdução

"Queremos prever quais clientes vão cancelar."

Suponha que o modelo acerte 99% dos cancelamentos — e entregue a lista na sexta-feira, depois do cancelamento.

Essa previsão tem valor?

Acurácia não é valor. Valor exige que exista **tempo**, **ação** e **recurso** para agir sobre a previsão.

Questão: quais são os elementos mínimos?

Listar os elementos mínimos de um problema supervisionado.

Quantos vocês conseguiram sem consultar?

Resposta

1. usuário e decisão;
2. restrição de recursos;
3. unidade de análise;
4. alvo observável y;
5. features disponíveis no corte;
6. horizonte de previsão.

MLS ▪ 2026.2

Aprender com dados

2

A estrutura de um conjunto de dados

Observações

Cada linha representa uma unidade em um momento definido: cliente–mês, empresa–trimestre, estudante–semana.

Variáveis

As colunas registram atributos $\mathbf{x} = (x_1, \ldots, x_p)$ e, quando existe, uma resposta y.

$$\mathbf{X} \in \mathbb{R}^{n \times p}, \qquad \mathbf{y} \in \mathbb{R}^n.$$

LEITURA DOS DADOS

Na oportunidade prospectada pela equipe, o que seria uma linha? Qual coluna registraria o resultado?

Aprendizado supervisionado

Morettin e Singer (2021) representam o problema por uma relação desconhecida entre atributos e resposta:

$$Y = f(\mathbf{X}) + \varepsilon.$$

- f contém a parte sistemática que podemos aprender com exemplos rotulados;
- ε reúne variação não explicada e impõe erro irredutível;
- $\hat{f}$ é estimada nos dados disponíveis e avaliada em observações que não participaram do ajuste.

A unidade, o alvo e o corte definem quais exemplos entram em $\mathbf{X}$ e $\mathbf{y}$. Uma formulação ruim não é corrigida por um algoritmo melhor.

Resposta, tarefa e decisão

Resposta y	Tarefa	Exemplo de decisão
Valor numérico	regressão	planejar estoque a partir da demanda mensal
Categoria	classificação	priorizar empresas para fiscalização

Segundo James et al. (2023), dois objetivos podem coexistir:

- **predição**: obter boas respostas para novos casos;
- **inferência**: entender como a resposta se associa aos atributos.

DECIDA

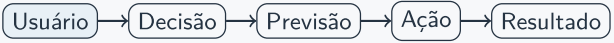
Na oportunidade da equipe, qual objetivo domina e por quê?

MLS ▪ 2026.2

Anatomia da formulação

3

Comece pelo fluxo de decisão



Note a direção: a decisão vem *antes* da previsão na especificação, ainda que venha depois na execução.

Se não existe ação plausível ao final da cadeia, uma previsão precisa continua inútil — e cara.

Onde o domínio de business entra

Princípio	Pergunta de formulação	Consequência técnica
Escassez	Quantos casos a organização consegue atender?	define k e a métrica em top-k
Custo de oportunidade	O que se faz hoje sem o modelo?	define o baseline
Margem	Para quais casos a previsão muda a ação?	define a população relevante
Trade-off	Errar para mais ou para menos custa igual?	define o limiar
Incentivos	Como as pessoas reagem ao modelo?	define o risco de degradação

O algoritmo não responde a essas perguntas. As respostas definem como o modelo será construído, avaliado e usado.

Template de uma pergunta preditiva

Estrutura

Para cada **[unidade]** em **[população]**, no momento **[corte]**, estimar **[alvo]** durante **[horizonte]**, usando **[dados disponíveis no corte]**, para apoiar **[decisão]** de **[usuário]**, sujeito a **[restrição]**.

REESCREVA

"Usar IA para melhorar as vendas." Produza uma versão que possa ser avaliada fora da amostra.

Uma resposta possível

Antes

"Usar IA para melhorar as vendas."

Depois

Para cada **cliente ativo** da **carteira do varejo Norte**, toda **segunda-feira**, estimar a **probabilidade de compra nos próximos 30 dias**, usando o **histórico transacional até domingo**, para apoiar a **seleção dos 200 clientes** que o **time comercial** consegue contatar na semana.

- a restrição (200 contatos) apareceu e mudou o problema: não interessa prever bem todo mundo, interessa ordenar bem os 200 primeiros;
- o corte temporal ficou explícito e verificável;
- o alvo é observável no sistema, sem circularidade.

Unidade e população

Unidade de análise

Entidade ou evento representado por uma linha: cliente–mês, pedido, escola–ano, estudante–semestre.

População-alvo

Conjunto de unidades sobre o qual a decisão será aplicada, com regras explícitas de inclusão e exclusão.

TESTE

Uma mesma pessoa pode aparecer em várias linhas? Quando isso muda a divisão treino–teste?

Se a unidade se repete, a divisão aleatória por linha vaza informação entre treino e teste.

A escolha da unidade é uma decisão, não um detalhe

Problema: apoiar a coordenação na prevenção de evasão.

Unidade	O que se prevê	Decisão que sustenta
Estudante	evadiu alguma vez no curso	nenhuma ação datada
Estudante–semestre	evadiu naquele semestre	priorização semestral
Estudante–semana	abandonou nos próximos 60 dias	fila semanal de contato

DECIDA

Qual unidade escolher se a coordenação se reúne toda segunda-feira e contata 50 estudantes por semana?

A cadência da decisão determina a unidade. Não o contrário.

Alvo e rótulo observável

Um bom alvo deve ser:

- observável e registrado, com definição estável no tempo;
- disponível somente após o horizonte, sem circularidade;
- próximo do resultado que importa para a decisão;
- suficientemente frequente e eticamente defensável.

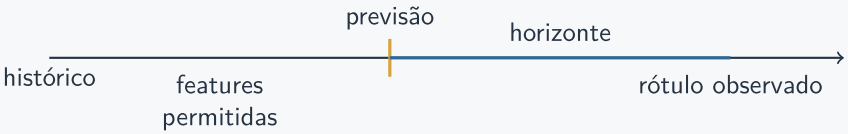
Um proxy conveniente pode medir a coisa errada — ou incorporar a desigualdade do processo que o gerou.

Alvo observável ou proxy?

Candidato a alvo	Tipo	Cuidado
Não renovou matrícula no prazo	observável	confunde trancamento com abandono
Estudante “desmotivado”	não observável	exige proxy; defina-o explicitamente
Registrou reclamação no SAC	proxy	mede quem reclama, não quem está insatisfeito
Não pagou o tributo em 90 dias	observável	depende da data de vencimento registrada
Foi aprovado em auditoria interna	proxy	reflete quem foi auditado, não quem errou

Todo proxy embute uma hipótese. Escreva a hipótese no Canvas, não na cabeça.

Corte temporal e horizonte



Tudo à esquerda do corte pode entrar no modelo. Tudo à direita é resultado — ou consequência da própria decisão.

ALERTA

Que informação do seu projeto só existe depois do corte e causaria vazamento?

Diagnóstico: o que pode entrar no modelo?

Prever abandono nos próximos 60 dias, com corte no domingo.

Variável candidata	Veredito	Motivo
Média das notas lançadas até domingo	permitida	anterior ao corte
Faltas registradas até domingo	permitida	anterior ao corte
Situação de matrícula ao fim do semestre	proibida	é o próprio alvo
Média final do semestre completo	proibida	inclui período posterior ao corte
Contatos feitos pela coordenação após o alerta	proibida	consequência da própria decisão
Curso, turno e forma de ingresso	permitida	estável; exige análise de equidade

Evidência de aprendizagem

Cada equipe classifica cinco variáveis do próprio projeto com este critério.

MLS ▪ 2026.2

Valor, restrição e avaliação

4

A restrição de capacidade redefine o problema

Sem restrição

Interessa acertar em toda a população. A métrica olha o conjunto inteiro.

Com capacidade k

A organização só age sobre k casos. Interessa a qualidade da **ordenação** no topo da lista.

Se a coordenação contata 50 estudantes por semana, um modelo que ordena bem os 50 primeiros e erra no resto é melhor do que um modelo uniformemente razoável.

A escassez transforma "prever bem" em "priorizar bem".

Baseline operacional: o custo de oportunidade

Compare com o que aconteceria *sem* o modelo:

- fila por ordem de chegada;
- regra especialista ou pontuação já em uso;
- média histórica ou prevalência do treino;
- seleção aleatória sob o mesmo orçamento.

O baseline é o custo de oportunidade do projeto: se o modelo não o supera, os recursos deveriam estar em outro lugar.

Qual baseline para cada caso?

Situação	Baseline defensável
Demanda mensal de merenda escolar	mesmo mês do ano anterior, não a média global (há sazonalidade)
Priorização de fiscalização tributária	a regra vigente do órgão, tipicamente maior débito declarado
Risco de evasão	prevalência histórica e ordenação por reprovações acumuladas

EM DUPLA — 5 MINUTOS

Escreva o baseline do seu projeto em uma frase executável. Quem o calcularia hoje, com quais dados?

Baseline que ninguém consegue calcular não é baseline: é retórica.

Custos dos erros

	Prevê positivo	**Prevê negativo**
Real positivo	ação potencialmente útil	falso negativo: oportunidade perdida não agir
Real negativo	falso positivo: custo e risco da ação	

DECISÃO

Qual erro é mais caro no seu projeto? A resposta muda conforme capacidade, gravidade e grupo afetado?

Formalizando: perda pontual e risco empírico

Uma **perda** atribui um número ao erro cometido em cada caso:

$$L(y_i, \hat{y}_i) \qquad \text{e} \qquad \widehat{R}(\hat{f}) = \frac{1}{n}\sum_{i=1}^{n} L\big(y_i, \hat{f}(x_i)\big).$$

- a **acurácia** é a perda 0–1 disfarçada: $L = \mathbf{1}\{y \neq \hat{y}\}$;
- ela supõe que errar para mais e errar para menos custam exatamente o mesmo;
- em decisão organizacional, quase nunca custam.

Escolher a métrica explicita quais erros importam para a decisão. Os custos vêm do contexto; a estatística ajuda a medi-los.

O limiar ótimo sai do valor esperado

Sejam B o benefício líquido de agir sobre um caso que de fato ocorreria e C o custo de agir sobre um caso que não ocorreria. Para um risco estimado $\hat{p}$:

$$\mathbb{E}[\text{agir}] = \hat{p}\,B - (1-\hat{p})\,C, \qquad \mathbb{E}[\text{não agir}] = 0.$$

Agir compensa quando

$$\begin{aligned} \hat{p}\,B - (1-\hat{p})\,C &> 0 \\ \hat{p}\,B &> C - \hat{p}\,C \\ \hat{p}\,(B+C) &> C \\ \hat{p} &> \frac{C}{B+C} \;\equiv\; t^{*}. \end{aligned}$$

O limiar não vem do algoritmo. Vem da razão entre os custos dos dois erros.

O limiar de 0,5 é um caso particular

Benefício B	**Custo** C	$t^* = C/(B+C)$	**Leitura**
10	1	$0{,}091$	agir já com 9% de risco
1	1	$0{,}500$	o famoso 0,5
1	4	$0{,}800$	só agir com quase certeza

O padrão de $0{,}5$ das bibliotecas corresponde à linha do meio: o caso em que os dois erros custam igual. Aceitá-lo sem pensar é assumir uma hipótese econômica por omissão.

Limiar ótimo ou fila: qual restrição morde primeiro?

A fila manda

Se há mais casos acima de t^* do que a capacidade k, o limiar que vale é o k-ésimo maior escore.

O limiar manda

Se há menos casos acima de t^* do que k, sobra capacidade e o critério econômico decide.

Descobrir qual das duas restrições morde primeiro é uma das primeiras perguntas a fazer ao demandante.

Vamos verificar isso numericamente agora.

Laboratório: o número que muda a decisão

Sem treinar modelo nenhum

O escore de risco é **dado** como insumo, como se viesse de um sistema já em operação. A partir de 15/10 aprenderemos a estimá-lo; hoje decidimos o que fazer com ele.

1. calcular prevalência e a acurácia de "sempre negativo";
2. comparar três regras de ordenação por `precision@k`;
3. ler a curva de ganho na altura da capacidade;
4. varrer o limiar e conferir o ótimo empírico contra $t^* = C/(B + C)$;
5. verificar qual restrição morde primeiro.

Base simulada com semente fixa. Não é evidência sobre instituição alguma.

Prever o desfecho não é prever o efeito

O problema da margem

O modelo estima *quem tem risco alto*. A decisão precisa de *quem mudaria de trajetória se fosse atendido*.

- quem tem risco altíssimo pode já estar fora do alcance da intervenção;
- quem tem risco baixo não precisa da intervenção;
- o ganho concentra-se na margem, e a previsão pura não a identifica.

Reconheça a limitação no Canvas. Não a resolveremos com ML supervisionado — e prometer o contrário é erro técnico, não modéstia.

Quando a métrica vira meta

Incentivos

Ao entrar em uso, o modelo altera o comportamento das pessoas medidas por ele.

- registros passam a ser preenchidos de forma estratégica;
- a variável que era boa preditora perde poder;
- o histórico deixa de representar o novo regime de operação.

Toda equipe deve registrar uma variável do seu projeto que poderia ser manipulada depois da implantação.

A métrica nasce da decisão

Situação da decisão	O que a métrica precisa capturar
Orçamento limitado a k casos	desempenho *dentro* da faixa priorizada
Falso negativo grave e ação barata	cobertura, com piso explícito
Probabilidade vira valor esperado	qualidade da calibração
Alvo contínuo	magnitude e distribuição do erro

Hoje não escolheremos a fórmula final. Registraremos o que um erro significa para o usuário.

Evidência de aprendizagem

Uma frase por equipe: “no nosso projeto, um falso positivo custa _____ e um falso negativo custa _____”.

MLS ▪ 2026.2

Clínica de oportunidades

5

Pitch em 90 segundos

1. organização, usuário e decisão;
2. restrição de capacidade ou orçamento;
3. unidade, alvo e horizonte candidatos;
4. dados que existem e forma de acesso;
5. benefício, risco e dúvida crítica;
6. próximo contato proposto.

Com sete equipes, apresentamos **uma oportunidade por equipe** em aula. As demais ficam na entrega escrita da Task 1.

Termine com uma pergunta a validar na escuta, não com uma promessa de solução.

Como ouvir um pitch

Quem ouve preenche, para cada pitch:

Força	o que torna essa oportunidade promissora
Pergunta	a suposição que precisa ser verificada com o demandante
Risco	o que pode inviabilizar o projeto até dezembro

Evidência de aprendizagem

Ficha de feedback preenchida por ouvinte, entregue ao final da aula.

Matriz de priorização

Pontue cada critério de 0 a 2 e some (máximo 12):

Critério	0 — 1 — 2
Decisão clara	inexistente — vaga — nomeada, com usuário e cadência
Alvo observável	não existe — proxy frágil — registrado e datado
Dados acessíveis	sem acesso — promessa — amostra ou esquema em mãos
Ação legítima	duvidosa — discutível — proporcional e justificável
MVP viável	improvável — apertado — factível até dezembro
Demandante disponível	sem contato — indireto — interlocutor confirmado

Regra de segurança

Pontuação alta não compensa impedimento ético ou de LGPD, nem ausência de supervisão. Esses dois critérios são eliminatórios, não somáveis.

Avançar, reformular ou recusar

- **avança** quem tem decisão nomeada, alvo registrado e interlocutor confirmado;
- **reformula** quem tem problema relevante mas alvo ou unidade mal definidos;
- **recusa** quem depende de coleta extensa, autorização demorada ou uso incompatível com privacidade.

Evidência de aprendizagem

Ranking justificado de até três oportunidades por equipe, com uma proposta principal e uma alternativa.

Manter sempre uma alternativa viva: acesso a dados é o que mais derruba projeto de semestre.

MLS ▪ 2026.2

Fechamento

6

Síntese da aula

- problema preditivo = decisão + unidade + alvo + tempo + dados + restrição;
- a cadência da decisão define a unidade de análise;
- a capacidade de atendimento define a métrica;
- o baseline é o custo de oportunidade do projeto;
- o limiar ótimo é $t^* = C/(B + C)$, e $0{,}5$ é apenas o caso simétrico;
- previsão de desfecho não identifica efeito de intervenção;
- o modelo em uso altera os incentivos de quem é medido por ele.

Task 2A e próxima aula

1. consolidar a ficha de formulação com os sete campos do template;
2. registrar baseline operacional e custos qualitativos dos erros;
3. preparar o roteiro de escuta, com perguntas não indutivas;
4. confirmar interlocutor, data e consentimento para registro.

EXIT TICKET INDIVIDUAL

Qual suposição do seu pitch mais precisa ser verificada pelo demandante — e que pergunta você fará para testá-la?

17/09: escuta com os demandantes, seleção dos desafios e início do Canvas de ML.

Referências

Morettin e Singer (2021), *Estatística e Ciência de Dados*, cap. 1, seções 1.5–1.6: notação, tipos de dados e paradigmas de aprendizado.

James, Witten, Hastie, Tibshirani e Taylor (2023), *An Introduction to Statistical Learning with Applications in Python*, cap. 2, seções 2.1–2.2: estimação de f, predição, inferência e avaliação.

James et al. (2023), cap. 4, seção 4.4.2: matriz de confusão, alteração do limiar e custos dos erros.

Leitura de apoio: Morettin e Singer, cap. 2, para preparação e estruturação dos dados.