Da pergunta aos dados admissíveis

Aula 4

Prof. Dr. Aléssio Tony Cavalcanti de Almeida
Ciência de Dados para Negócios – UFPB

João Pessoa, 2026

Consumo e renda

Uma amostra registra renda disponível Y_i e consumo C_i de cada unidade i.

$$C_i = \alpha + \beta Y_i + e_i$$

- α: consumo autônomo;
- β: propensão marginal a consumir;
- e_i: parcela não explicada pela renda.

Pergunta de abertura

Que dados e quais decisões de preparação tornam α e β mensuráveis e interpretáveis?

Fonte: Morettin e Singer (2021), Exemplo 2.1, p. 25.

Três perguntas com os mesmos dados

Objetivo	Pergunta	Evidência necessária
Descrição	Como consumo e renda aparecem nesta amostra?	tabela, gráfico e medidas resumo
Predição	Quanto uma nova unidade tende a consumir?	desempenho em unidades não usadas no ajuste
Explicação causal	Quanto o consumo mudaria se a renda fosse alterada?	desenho e pressupostos que sustentem causalidade

Uma reta ajustada a dados observacionais não identifica automaticamente o efeito causal da renda.

Resultados da aula

Ao final, cada estudante deverá conseguir:

- transformar uma pergunta de trabalho em unidade, população, variáveis e horizonte;
- distinguir dados transversais, longitudinais e séries temporais;
- construir resumos que revelem distribuição, associação e cobertura;
- justificar decisões sobre ausências, categorias e valores extremos;
- diagnosticar leakage e propor uma partição coerente com o uso;
- explicar por que o pré-processamento deve aprender apenas com o treino.

Evidência de aprendizagem

Diagnóstico individual + notebook de auditoria + plano de preparação da equipe.

Sequência da aula

14h00–14h50	caso consumo–renda; pergunta, unidade, variável e formato
14h50–15h40	exploração da RAIS: alvo, distribuição e relações
15h40–15h50	intervalo
15h50–16h30	qualidade, leakage, partição e baseline
16h40–17h30	laboratório com dados ou esquema do projeto
17h30–18h00	revisão cruzada, plano de correção e ponte para regressão

MLS ▪ 2026.2

Da pergunta à tabela

1

A unidade determina o significado da linha

Unidade de investigação

Entidade, evento ou par entidade–tempo em que as variáveis foram observadas.

- indivíduo, família, empresa ou município;
- transação, pedido, atendimento ou sinistro;
- cliente–mês, escola–ano ou empresa–trimestre.

CONSUMO–RENDA

A unidade é pessoa ou família? O significado de renda e consumo muda com essa escolha?

População, amostra e uso

Elemento	Pergunta operacional
População de interesse	sobre quem queremos aprender ou prever?
População registrada	quem consegue aparecer na fonte de dados?
Amostra observada	quais unidades e períodos foram efetivamente coletados?
População de uso	sobre quem o modelo receberá novos casos?

COBERTURA

Quem ficaria invisível numa base de consumo obtida apenas por cartão de crédito?

Definição operacional de renda e consumo

"Renda" pode significar renda individual, familiar, disponível, mensal ou anual. "Consumo" pode incluir apenas despesas monetárias ou também serviços imputados.

Uma definição operacional informa

fonte, período de referência, unidade de medida, regras de inclusão, momento de disponibilidade e tratamento de casos especiais.

ESPECIFICAÇÃO

Escreva uma definição de renda que outra equipe conseguiria medir sem perguntar o que você quis dizer.

Dicionário orientado ao uso

Campo	significado	tipo/unidade	domínio ou risco
`id_familia`	unidade familiar	texto	chave pseudonimizada
`renda_mensal`	renda familiar no mês	R$/mês	fonte e período de referência
`consumo_mensal`	despesa familiar no mês	R$/mês	alvo; observado após o período
`idade_chefe`	idade da pessoa de referência	anos	limites plausíveis
`sexo_chefe`	sexo informado	categoria	cobertura e codificação
`estado_civil_chefe`	situação conjugal	categoria	padronização de rótulos
`escolaridade_chefe`	maior nível concluído	categoria ordinal	quatro valores ausentes
`zona, estado`	localização da família	categoria	rural/urbana; PB
`pessoas_familia`	moradores da unidade	contagem	composição familiar

PROJETO

O tipo no arquivo coincide com a natureza estatística e com a unidade de medida?

Amostra POF simulada da Paraíba

Família	município	zona	renda	consumo	idade	sexo	estado civil	escolaridade
F001	Sousa	urbana	4.450	3.340	35	M	divorciado(a)	superior incompleto
F002	Pombal	urbana	3.630	3.370	46	F	solteiro(a)	médio incompleto
F003	Patos	rural	3.220	3.440	57	M	viúvo(a)	fundamental incompleto
F004	Cabedelo	urbana	8.450	6.930	68	F	união estável	superior completo

Arquivo materializável

`dados_pof_pb_simulados.csv`: 96 famílias, 12 municípios paraibanos, rendas e consumos em R$/mês, atributos do chefe e localização.

Os dados são inteiramente sintéticos: servem ao ensino e não estimam resultados oficiais da POF.

PRIMEIRA LEITURA

Qual variável é o alvo? Quais atributos já existem antes de observar o consumo do mês?

Três estruturas de dados

Estrutura	Unidade típica	Dependência relevante
Transversal	pessoa observada uma vez	diferenças entre unidades no mesmo período
Longitudinal ou painel	pessoa–período	medidas da mesma pessoa se relacionam no tempo
Série temporal	período de uma população	ordem, tendência e sazonalidade

A estrutura define a partição: linhas repetidas da mesma entidade não são independentes.

Formato largo e formato longo

Largo

id	renda_1	renda_2	renda_3
A	2,1	2,3	2,4
B	1,4	1,5	1,8

Longo

id	mês	renda
A	1	2,1
A	2	2,3
A	3	2,4
B	1	1,4

ESCOLHA

Qual formato permite agrupar, visualizar e particionar por entidade e tempo com menos ambiguidade?

MLS ▪ 2026.2

Resumos que informam o modelo

2

Caso comum: remuneração na RAIS

Pergunta preditiva

Quanto da remuneração de um vínculo formal conseguimos antecipar com atributos disponíveis no ano de referência?

Fonte: microdados públicos não identificados da RAIS, MTE.

- unidade: vínculo de trabalho;
- alvo: log da remuneração média nominal;
- cobertura: emprego formal registrado;
- uso: exercício de predição, não efeito causal.

Contrato do recorte da RAIS

Elemento	Definição para o laboratório
População registrada	vínculos formais presentes no recorte fornecido pelo professor
Linha	um vínculo no ano de referência
Alvo	$\log(1 + \text{remuneração média nominal})$
Atributos candidatos	idade, escolaridade, horas, tempo no emprego, ocupação, setor e município
Uso simulado	estimar remuneração para vínculos de municípios não usados no ajuste
Limite	resultados não representam trabalho informal nem identificam efeito causal

O gráfico vem antes da reta

No exemplo de Morettin e Singer, o diagrama de dispersão permite examinar:

- direção e forma da relação entre renda e consumo;
- mudança da dispersão ao longo da renda;
- observações influentes e regiões sem cobertura;
- subgrupos que podem seguir relações diferentes.

ANTECIPAÇÃO

Que padrão no gráfico tornaria uma única reta inadequada?

O gráfico orienta a especificação; ele não comprova causalidade nem desempenho preditivo.

Quatro gráficos, quatro perguntas

Gráfico	Pergunta	Decisão possível
histograma do alvo	há assimetria ou cauda longa?	comparar escala original e log
boxplot por escolaridade	grupos diferem em centro e dispersão?	preservar grupo e investigar interação
dispersão X–Y	a relação parece linear?	reta, transformação ou modelo flexível
faltantes por período/grupo	a ausência está concentrada?	corrigir fonte, indicador ou recorte

Associação antes da regressão

Para duas variáveis quantitativas, examinar em conjunto:

- diagrama de dispersão e região de suporte;
- direção, forma e intensidade da associação;
- correlação, sempre acompanhada do gráfico;
- dispersão vertical ao longo do preditor;
- relações distintas entre grupos.

DIAGNÓSTICO

Uma correlação próxima de zero exclui uma relação curva? Uma correlação alta torna a relação causal?

Distribuição de uma variável

Pergunta	Resumo	Risco revelado
Onde estão os valores?	mediana, média e quantis	centro pouco representativo
Quanto variam?	desvio padrão e intervalo interquartil	instabilidade e escala
Qual é a forma?	histograma e boxplot	assimetria, caudas e multimodalidade
Quem não aparece?	contagem e taxa de ausência	seleção e cobertura

Média e desvio padrão isolados podem esconder assimetria, grupos e erros de registro.

Frequências e tabelas de contingência

```
pd.crosstab(
    dados["setor"], dados["inadimplente"],
    margins=True
)

pd.crosstab(
    dados["setor"], dados["inadimplente"],
    normalize="index"
)
```

LEITURA

A segunda tabela responde “quantos inadimplentes há?” ou “qual a proporção dentro de cada setor?”

Resumos por grupo

```
resumo = (
    dados.groupby("grupo")["renda"]
         .agg(n="size", media="mean", mediana="median", desvio="std")
)

faltantes = dados.groupby("mes")["renda"].apply(
    lambda s: s.isna().mean()
)
```

DIAGNÓSTICO

Se a taxa global de ausência é 8%, mas chega a 40% no último mês, qual resumo deve orientar a decisão?

Valores extremos exigem investigação

Um valor distante pode representar:

- erro de digitação, unidade ou integração;
- evento raro legítimo;
- unidade pertencente a outra população;
- observação influente que altera fortemente o ajuste.

DECISÃO

Uma renda cem vezes maior que a mediana deve ser corrigida, removida, transformada ou preservada? Que evidência decide?

Boxplot sinaliza observações para investigação; não autoriza exclusão automática.

O resumo deve levar a uma decisão

Achado	Pergunta seguinte	Possível ação
ausência concentrada no tempo	mudou o processo de coleta?	corrigir fonte ou criar regra temporal
categoria rara	é erro, grupo legítimo ou baixa cobertura?	padronizar, preservar ou agrupar
cauda longa	escala ou população explica a cauda?	transformação ou modelo adequado
relação diferente por grupo	o grupo altera o uso ou a equidade?	interação, recorte ou análise separada

MLS ▪ 2026.2

Dados admissíveis

3

Contrato antes do tratamento

Elemento	Pergunta verificável
Chave e unidade	quais campos tornam uma linha única?
População e cobertura	quem, onde e quando aparece?
Alvo	qual evento histórico, fonte e data de disponibilidade?
Corte e horizonte	o que existe ao decidir e quando o alvo é observado?
Atualização	frequência, versão, responsável e mudança de definição?
Restrições	acesso, finalidade, retenção e usos vedados?

Qualidade com denominador e recorte

Para a variável j, a taxa de ausência é

$$m_j = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}(x_{ij} \text{ ausente}).$$

- informar contagem e denominador;
- comparar por período, origem e grupo relevante;
- verificar se filtros e junções mudaram a população;
- registrar a consequência para a decisão e para o modelo.

CÁLCULO

18 ausências em 120 linhas correspondem a qual taxa? E se 15 ocorrerem no último mês?

Faltante descreve o processo de coleta

- “não se aplica”, recusa, falha e não medição têm significados distintos;
- excluir linhas redefine a população;
- imputar preserva casos, mas adiciona uma hipótese;
- uma categoria de ausência pode ser informativa;
- a imputação deve aprender seus parâmetros no treino.

PROJETO

Para uma variável com ausência, escreva o mecanismo provável e a evidência necessária para confirmá-lo.

Junções podem alterar a população

Antes e depois de cada `merge`, registrar:

- cardinalidade esperada: 1:1, 1:m ou m:1;
- linhas e chaves únicas;
- correspondências à esquerda, à direita e em ambas;
- duplicação inesperada e unidades perdidas;
- perda por período ou grupo relevante.

DECISÃO

Uma junção eliminou 12% das unidades. Que evidência permitiria aceitá-la?

O teste do relógio

Para cada atributo x_j:

1. definir o instante da previsão t_0;
2. identificar quando o valor foi gerado;
3. identificar quando entrou no sistema;
4. verificar se surgiu após o desfecho ou como consequência da decisão.

Critério de admissibilidade

O atributo precisa existir no sistema e estar disponível ao usuário no instante real da previsão.

Três famílias de leakage

Alvo	o atributo contém o desfecho ou uma proxy construída depois dele.
Tempo	o atributo chega ao sistema depois do instante da previsão.
Partição	a mesma entidade ou uma transformação deixa o teste influenciar o ajuste.

CLASSIFICAÇÃO

Diagnóstico após alta; média calculada na base completa; mesmo cliente em treino e teste.

A partição representa o uso

Partição	Cenário simulado	Condição
Aleatória	novas unidades no mesmo contexto	observações independentes
Por grupo	nova pessoa, empresa ou território	entidade não cruza a fronteira
Temporal	uso futuro após dados históricos	treino antecede teste
Contextual	aplicação em instituição não observada	contexto inteiro fica reservado

FRASE

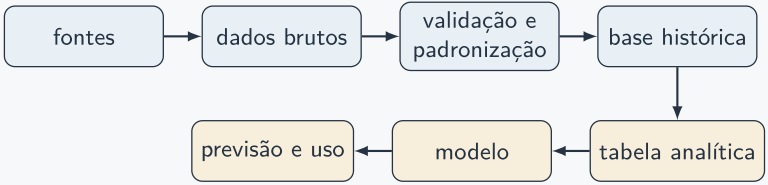
"O teste simula o uso em ...; por isso separamos por ...".

MLS ▪ 2026.2

Do dado ao modelo

4

Arquitetura mínima do projeto



Escopo do semestre

Preservar o bruto, automatizar o preparo e documentar versões e atualização.

Particionar antes do preparo

```
X_treino, X_teste, y_treino, y_teste = train_test_split(
    X, y, test_size=.25, random_state=20261001
)

preparo.fit(X_treino)
Xtr = preparo.transform(X_treino)
Xte = preparo.transform(X_teste)
```

Tempo ou grupos exigem outro divisor; a fronteira entre treino e teste permanece.

Baseline antes da reta

Sem usar os atributos, o baseline de regressão prevê para todos os casos a média observada no treino:

$$\widehat{y}_i = \overline{y}_{\text{treino}}.$$

Seu erro no teste estabelece a referência que qualquer modelo precisa superar.

Ponte para o capítulo 6

A reta será útil se reduzir o erro fora da amostra e se seus resíduos não revelarem inadequações importantes.

INTERPRETAÇÃO

O que significa uma regressão ter RMSE maior que o baseline da média?

Preparação por tipo

```
preparo = ColumnTransformer([
  ("num", Pipeline([
      ("imputar", SimpleImputer(strategy="median")),
      ("escalar", StandardScaler())
  ]), colunas_numericas),
  ("cat", Pipeline([
      ("imputar", SimpleImputer(strategy="most_frequent")),
      ("codificar", OneHotEncoder(handle_unknown="ignore"))
  ]), colunas_categoricas)
])
```

INTERPRETAÇÃO

Que quantidades o `fit` aprende?

Preparação incorpora hipóteses

Decisão	Hipótese	Sinal de problema
mediana	centro do treino substitui ausências	grupos e períodos muito diferentes
moda	categoria comum é substituto aceitável	ausência tem significado próprio
one-hot	categorias são estados discretos	cardinalidade alta ou categoria nova
escala padrão	média e desvio são estáveis	caudas e extremos dominam

Cada transformação precisa de justificativa, ajuste no treino e registro reproduzível.

MLS ▪ 2026.2

Laboratório e transição

5

Notebook da aula 04

No `auditoria_aula_04.ipynb`, a equipe deverá:

1. preencher contrato, chave, alvo, tempo, grupos e tipos;
2. gerar frequências, resumos por grupo e perfil de qualidade;
3. examinar distribuição, extremos, faltantes e cobertura;
4. classificar variáveis pelo relógio da decisão;
5. criar a partição coerente com o uso;
6. ajustar o pré-processador apenas no treino.

Saídas do laboratório

1. **Contrato**: unidade, chave, população, alvo, corte e horizonte.
2. **Resumo orientado**: tabela ou gráfico acompanhado de uma decisão.
3. **Qualidade**: problema, evidência, recorte, impacto e tratamento proposto.
4. **Leakage**: variável, relógio e decisão permitir/proibir.
5. **Avaliação**: partição, cenário simulado, baseline e métrica planejada.

Evidência de aprendizagem

Notebook executável + diagnóstico individual + plano de correção com responsável e prazo.

Revisão cruzada

Outra equipe procurará uma ameaça que comprometa:

- significado da unidade ou da variável;
- cobertura da população;
- disponibilidade do atributo no instante da decisão;
- independência entre treino e teste;
- reprodutibilidade de limpeza, integração ou transformação.

DEVOLUTIVA

Registrar evidência, consequência e a menor correção viável.

A pergunta que fica para 08/10

Depois de definir e auditar os dados, retornamos a

$$C_i = \alpha + \beta Y_i + e_i.$$

- como estimar α e β a partir da amostra?
- que critério define a melhor reta?
- quanto o modelo erra em novas observações?
- que padrão nos resíduos indica inadequação?

Próxima aula: regressão linear, mínimos quadrados, comparação com o baseline e resíduos.

Referências

Morettin, P. A.; Singer, J. M. (2021). *Estatística e Ciência de Dados*. Cap. 2: preparação, planilhas, tabelas, gráficos e bancos de dados; cap. 3: frequências, medidas resumo e boxplots; Exemplo 2.1, p. 25.

James, G. et al. (2023). *An Introduction to Statistical Learning with Applications in Python*. Cap. 5.

Scikit-learn. Documentação de `Pipeline`, `ColumnTransformer`, imputação, codificação e divisores de amostra.

Brasil. Lei 13.709/2018, Lei Geral de Proteção de Dados Pessoais.

Ministério do Trabalho e Emprego. Microdados públicos da RAIS e documentação do PDET.