Regressão linear simples

Aula 5

Prof. Dr. Aléssio Tony Cavalcanti de Almeida
Ciência de Dados para Negócios – UFPB

João Pessoa, 2026

Pergunta da aula

Na aula anterior, o baseline previu a média do treino para todos os casos.

Questão

Uma reta construída com um atributo reduz o erro em novas observações?

Evidência de aprendizagem

Comparação entre baseline e regressão simples na mesma partição de teste.

Resultados da aula

Ao final, cada estudante deverá conseguir:

- escrever o modelo linear e distinguir erro de resíduo;
- interpretar intercepto, inclinação e valor previsto;
- explicar o critério de mínimos quadrados;
- ajustar uma regressão dentro do pipeline;
- comparar seu erro de teste com o baseline;
- reconhecer extrapolação e interpretação causal indevida.

Sequência

14h00–14h40	função de regressão, reta e interpretação
14h40–15h20	mínimos quadrados e resíduos
15h20–15h40	cálculo guiado
15h40–15h50	intervalo
15h50–16h30	treino, teste, baseline e métricas
16h40–17h35	laboratório com RAIS ou dados do projeto
17h35–18h00	comparação, revisão e exit ticket

MLS ▪ 2026.2

Reta e interpretação

1

Função de regressão

Para um atributo X, a média condicional da resposta pode ser representada por

$$E(Y \mid X = x) = \beta_0 + \beta_1 x.$$

O modelo para cada observação é

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

- a reta descreve a média de Y para cada valor de X;
- ε_i reúne variação não representada pela reta.

Parâmetros da reta

Parâmetro	Interpretação matemática	Verificação substantiva
β_0	média esperada quando $X = 0$	zero existe e está no suporte observado?
β_1	variação média em Y por unidade de X	as unidades e a escala tornam a variação interpretável?

Um coeficiente associado a dados observacionais não identifica automaticamente um efeito causal.

Consumo e renda

No exemplo de Morettin e Singer,

$$C_i = \alpha + \beta Y_i + e_i.$$

- α: consumo médio previsto quando a renda é zero;
- β: variação média prevista no consumo por unidade de renda;
- e_i: diferença entre consumo observado e média condicional populacional.

SUPORTE

A amostra contém rendas próximas de zero? O significado econômico de α depende da resposta.

Salário e educação na RAIS

Para o caso comum da turma,

$$\log(1 + salario_i) = \beta_0 + \beta_1 educacao_i + \varepsilon_i.$$

Leitura preditiva

β_1 resume como a resposta média varia entre níveis de educação na especificação escolhida.

LIMITE

Quais diferenças entre trabalhadores permanecem dentro de ε_i?

MLS ▪ 2026.2

Mínimos quadrados

2

Valores ajustados e resíduos

Depois de estimar a reta,

$$\widehat{Y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 X_i, \qquad \widehat{e}_i = Y_i - \widehat{Y}_i.$$

Erro quantidade populacional não observada ε_i.

Resíduo diferença calculada na amostra $\widehat{e}_i$.

SINAL

O que significa um resíduo positivo no problema de remuneração?

Critério de mínimos quadrados

O ajuste escolhe os coeficientes que minimizam

$$S(\beta_0, \beta_1) = \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 X_i)^2.$$

Ele penaliza erros grandes de forma quadrática e produz uma solução única quando há variação em X.

Consequência

Observações extremas na resposta podem alterar fortemente a reta.

Estimadores da regressão simples

$$\widehat{\beta}_1 = \frac{\sum_i (X_i - \overline{X})(Y_i - \overline{Y})}{\sum_i (X_i - \overline{X})^2}, \qquad \widehat{\beta}_0 = \overline{Y} - \widehat{\beta}_1 \overline{X}.$$

Logo,

$$\widehat{\beta}_1 = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)}$$

quando covariância e variância usam o mesmo denominador.

LEITURA

Por que pouca variação em X torna a inclinação instável?

Propriedades geométricas

Com intercepto, a reta de mínimos quadrados:

- passa pelo ponto $(\overline{X}, \overline{Y})$;
- produz resíduos cuja soma é zero no treino;
- produz resíduos ortogonais ao preditor no treino.

Essas propriedades são do ajuste no treino e não garantem erro pequeno no teste.

MLS ▪ 2026.2

Predição fora da amostra

3

Baseline e regressão

Modelo	Previsão	Informação utilizada
baseline	$\widehat{y} = \overline{y}_{treino}$	apenas o alvo no treino
regressão simples	$\widehat{y} = \widehat{\beta}_0 + \widehat{\beta}_1 x$	alvo e um atributo no treino

O teste deve permanecer idêntico nas duas avaliações.

MAE e RMSE

$$MAE = \frac{1}{n}\sum_i |y_i - \widehat{y}_i|, \qquad RMSE = \sqrt{\frac{1}{n}\sum_i (y_i - \widehat{y}_i)^2}.$$

- MAE mantém a unidade da resposta e pondera erros linearmente;
- RMSE atribui peso maior aos erros grandes;
- a métrica deve refletir o custo do erro no uso planejado.

Interpolação e extrapolação

Interpolação previsão dentro da região de valores observados no treino.

Extrapolação previsão fora dessa região.

Uma reta continua numericamente além da amostra, mas os dados deixam de sustentar sua forma.

AUDITORIA

Compare mínimo e máximo do preditor em treino e teste. Que previsões são extrapolações?

Pipeline da regressão

```
modelo = Pipeline([
    ("preparo", preparo),
    ("regressao", LinearRegression())
])

modelo.fit(X_treino, y_treino)
pred = modelo.predict(X_teste)
```

O pipeline aprende imputação, escala e coeficientes apenas com o treino.

MLS ▪ 2026.2

Laboratório

4

Experimento da equipe

1. preservar a partição da aula 4;
2. escolher um preditor com justificativa substantiva;
3. calcular baseline, MAE e RMSE;
4. ajustar a regressão simples;
5. interpretar os coeficientes;
6. identificar extrapolações;
7. comparar o modelo com o baseline.

Tabela de comparação

Modelo	MAE no teste	RMSE no teste	Observação
Média do treino			referência
Regressão simples			atributo: _____

CONCLUSÃO

O atributo acrescentou informação preditiva? A diferença é relevante para o uso?

Ponte para a aula 6

Um número de erro não mostra onde o modelo falha. Na próxima aula, examinaremos:

- padrão dos resíduos;
- incerteza dos coeficientes e das previsões;
- linearidade, variância e observações influentes;
- efeito da transformação logarítmica.

Evidência de aprendizagem

Exit ticket: principal limite da regressão simples ajustada pela equipe.

Referências

Morettin, P. A.; Singer, J. M. (2021). *Estatística e Ciência de Dados*. Cap. 6, seções 6.1–6.2.

James, G. et al. (2023). *An Introduction to Statistical Learning with Applications in Python*. Caps. 3 e 5.

Scikit-learn. Documentação de `LinearRegression`, `Pipeline` e métricas de regressão.