PROJETO INDIVIDUAL

O seu Remunerômetro

Aprendizagem de Máquina Supervisionada – UFPB/CCSA

Prazo: 05/11/2026, até 13h59 | **Natureza:** Individual | **Formato:** Notebook executado + exportação em PDF ou HTML

Objetivo da entrega. Construir, de ponta a ponta e com decisões justificadas, um modelo que apoie uma decisão real a partir dos vínculos formais da RAIS 2025 (disponível em `ftp://ftp.mtps.gov.br/pdet/microdados/`): escolher o usuário e a pergunta, decidir entre previsão do valor (regressão) ou de uma faixa (classificação), selecionar e justificar atributos, validar sem vazamento, ajustar hiperparâmetros, diagnosticar sobreajuste e comparar alternativas de modelagem.

Peso na avaliação. Esta entrega compõe a I_1 (verificação individual da A1). A nota da unidade segue $A_k = 0{,}60\,P_k + 0{,}40\,I_k$, em que P_k é o produto coletivo e I_k a verificação individual. Composição: $I_1 = 0{,}5 \times$ projeto remunerômetro (05/11) $+ 0{,}5 \times$ sustentação oral (12/11).

Por que este projeto

Nas aulas 5 e 6, o Remunerômetro foi construído em sala, com as decisões tomadas pelo professor. Agora as decisões são suas. O projeto exercita, em um dado comum a toda a turma, exatamente o que a sua equipe fará com o dado do demandante: formular, preparar, validar, comparar e escolher. Por isso ele compõe a sua verificação individual da A1.

Base e partição. Crie uma base analítica (ver exemplo da seção 9 do laboratório 5). Do treino, cada estudante sorteia a sua amostra de trabalho com a própria semente (seção 3).

1. Usuário, decisão e tipo de problema

Escolha **um** uso entre os abaixo ou proponha outro, com a mesma estrutura. Registre: quem usa, que decisão toma, em que momento a previsão é feita e quanto custa cada tipo de erro.

Usuário	Decisão	Saída natural
agência de emprego (SINE)	informar ao candidato a remuneração de referência para uma vaga	valor (R$)
empresa contratante	definir a faixa salarial de entrada para um cargo	valor (R$)
programa estadual de qualificação	priorizar vínculos com baixa chance de passar de 1,5 SM	sim/não
instituição de crédito	pré-aprovar limite maior para quem tem renda acima de 2 SM	sim/não

Justifique por escrito: (a) por que o problema é de **regressão** ou de **classificação**; (b) qual métrica traduz o custo do erro para esse usuário (MAE ou RMSE em R$; precision, recall ou resultado líquido com B e C); (c) se for classificação, como o limiar será escolhido.

Escopo. A A1 cobre regressão linear e regularizada. Quem escolher classificação deve usar regressão logística com e sem penalização (ℓ_2 e ℓ_1) e aplicar os mesmos cuidados de validação; a ideia de comparar alternativas é idêntica.

2. Atributos

Para **cada** atributo utilizado, preencha uma linha:

Atributo	Disponível no momento do uso?	Sinal esperado	Argumento econômico	Risco (vazamento, equidade, cardinalidade)

Regras: nenhuma variável derivada de remuneração entra como atributo. Decida e justifique a codificação de escolaridade (anos ou categorias), idade (linear, quadrática), CBO (6, 4 ou 2 dígitos) e município (todos, agrupados ou `min_frequency`). Se usar sexo ou raça/cor, discuta em duas linhas se o uso é legítimo para a decisão escolhida.

3. Amostra individual e partição

1. `SEMENTE` = os **seis últimos dígitos da sua matrícula**. Ela deve aparecer na primeira célula.
2. Sorteie $n = 2.000$ vínculos do treino com essa semente. Esse é o seu $\mathcal{D}_{\text{treino}}$.
3. Hiperparâmetros são escolhidos por validação cruzada de 5 dobras **dentro** de $\mathcal{D}_{\text{treino}}$ (`KFold`, ou `StratifiedKFold` na classificação).
4. Todo pré-processamento fica dentro do `Pipeline`.
5. O teste é aberto **uma única vez**, depois de o procedimento estar congelado.

Informe n e p (número de colunas depois do *one-hot*) e comente a razão p/n.

4. Alternativas de modelagem

Compare, no mínimo:

	Regressão	Classificação
referência	baseline (média ou mediana do treino)	baseline (prevalência ou classe majoritária)
sem penalização	MQO	logística com `C` muito grande
penalização ℓ_2	ridge	logística ℓ_2
penalização ℓ_1	lasso	logística ℓ_1
opcional	elastic net; outra especificação de atributos	elastic net; outro conjunto de atributos

Para cada modelo penalizado, declare a grade de busca, o valor escolhido e por que a grade cobre a região relevante (o ótimo não pode estar na borda da grade).

5. Diagnóstico de sobreajuste

1. Tabela com o erro de **treino**, de **validação cruzada** (média e desvio entre dobras) e de **teste** para cada modelo.
2. **Curva de validação** do modelo penalizado escolhido: erro de treino e de validação em função de λ (ou de `C`). Indique as regiões de sobreajuste e de subajuste.
3. Interprete a distância entre treino e validação: qual modelo sobreajusta mais e por quê, em termos de p/n e de categorias raras.

6. Avaliação e escolha

1. Reportar pelo menos duas métricas. Regressão: RMSE em log e MAE em R$. Classificação: AUC, matriz de confusão, precision e recall no limiar escolhido.
2. Erro por grupo (escolaridade e sexo, no mínimo). Algum grupo é sistematicamente pior?
3. Escolher o modelo final pela métrica ligada à decisão, não pela maior complexidade.
4. Explicar, em até cinco linhas e com notação, o **critério minimizado** pelo modelo final e o que o hiperparâmetro controla.
5. Uma limitação do modelo e um risco de uso indevido.

Verificação individual. Na sustentação oral de 12/11, haverá itens sobre **o seu próprio notebook**: explicar um número da sua tabela, justificar uma escolha de atributo ou de hiperparâmetro, e prever o que mudaria se uma decisão fosse alterada. Quem não souber explicar a própria entrega não recebe a nota correspondente do projeto.

Estrutura obrigatória do notebook

Use o modelo `projeto_remunerometro_template.ipynb`. As seções em Markdown são obrigatórias e devem conter as respostas em texto, não apenas código. Seções: (0) identificação e semente; (1) usuário, decisão e tipo de problema; (2) atributos e codificação; (3) amostra, partição e validação; (4) modelos e hiperparâmetros; (5) diagnóstico de sobreajuste; (6) avaliação no teste e escolha final; (7) limitações, riscos e declaração de uso de IA.

Checklist antes de enviar

- ☐ A semente é a da minha matrícula e está na primeira célula.
- ☐ O notebook executa do início ao fim, sem intervenção manual e sem caminhos absolutos.
- ☐ O teste não foi usado para escolher atributos, modelo, λ ou limiar.
- ☐ Todo pré-processamento está dentro do pipeline.
- ☐ Há pelo menos quatro linhas na tabela de comparação, incluindo o baseline.
- ☐ O valor escolhido de cada hiperparâmetro não está na borda da grade.
- ☐ A curva de validação está no notebook e foi interpretada.
- ☐ As métricas estão ligadas ao custo do erro do usuário escolhido.
- ☐ O critério do modelo final foi escrito com notação.

☐ A declaração de uso de IA está preenchida.

Rubrica

Dimensão	O que será observado	Peso
Formulação	Usuário, decisão, momento da previsão; escolha entre regressão e classificação justificada; métrica ligada ao custo do erro.	15
Atributos	Disponibilidade no momento do uso, sinal esperado, argumento econômico, riscos e codificação justificada.	15
Validação sem vazamento	Semente individual, teste intocado, validação cruzada no treino, pré-processamento no pipeline.	15
Modelagem e hiperparâmetros	Pelo menos quatro alternativas; grades declaradas e adequadas; escolha documentada.	20
Sobreajuste	Tabela treino × validação × teste, curva de validação e interpretação correta.	15
Avaliação e escolha	Duas ou mais métricas, erro por grupo, escolha coerente com a decisão, limiar justificado (classificação).	10
Camada formal e comunicação	Critério do modelo final escrito com notação; texto claro; reprodutibilidade.	10

Situações que zeram o item correspondente. Escolher qualquer coisa olhando o teste zera "Validação sem vazamento". Notebook que não executa zera "Modelagem". Semente diferente da matrícula ou resultados idênticos aos de outro estudante levam à anulação do projeto e à convocação para defesa oral.

Uso de IA generativa

Permitido como apoio, com declaração obrigatória ao final do notebook: ferramenta, finalidade e quais células foram influenciadas. Você responde integralmente pelo que entregou e deve ser capaz de explicar qualquer linha na sustentação oral de 12/11.

Como submeter

- Enviar pelo SIGAA, até 05/11/2026 às 13h59, o notebook executado (`.ipynb`) e sua exportação em PDF ou HTML.
- Nomear os arquivos como `REM_matricula_primeironome.ipynb` e `.pdf`/`.html`.
- Não enviar a base de dados.